

2026 년 오픈소스 개발자대회 결과보고서

작성 안내: 남은 placeholder 는 시연 영상 URL 1 곳뿐입니다(\$1 프로젝트 개요 표). 영상 제작 후 [유튜브 링크 기재]를 교체하고 python tools/build_report_docx.py 로 재생성하세요.

과제 및 팀 정보 기재			
항 목	내 용	항 목	내 용
접수번호	289	팀 명	Truth History
팀 인원 (팀장 포함)	1 명	참가부문	일반
과제유형	자유과제(인공지능)		

□ 결과보고서

1. 프로젝트 개요

항목	내용
프로젝트명	Truth History SDK — 생성형 AI 한국사 왜곡·멀티미디어 위변조 통합 탐지 오픈소스 프레임워크
프로젝트 등록 URL	https://github.com/kimneche0419-rgb/Thruth_History
시연 영상	[유튜브 링크 기재]
프로젝트 소개	생성형 AI 로 인한 한국 역사 할루시네이션(그럴듯한 거짓 역사 정보)과 멀티미디어 위변조(딥페이크·AI 복제 음성·합성 이미지)를 텍스트 고증 검증·ELA 이미지 합성·페이스 스왑·복제 음성 탐지 모듈로 단일 SDK 로 통합 탐지 하고, 판정 근거를 설명 가능한(XAI) API/CLI 리포트로 제공하는 오픈소스 가드레일 프레임워크
개발 배경 및 목적	① LLM 이 사료와 일치하지 않는 거짓 역사 정보를 출처까지 꾸며 대량 생성·유포(한국사 할루시네이션)하며 교육·언론·SNS 로 재생산되는 문제, ② 역사 인물 사칭 딥페이크·AI 복제 음성·합성 역사 사진 등 멀티미디어 위변조 확산 문제, ③ 기존 공개 도구가 단일 기능에 파편화되어 텍스트·이미지·영상·오디오 교차

	검증이 불가능한 구조적 공백에 대응. 뉴스·교육·공공 시스템이 자사 인프라에 임베딩 가능한 단일 규격의 한국 역사 데이터 안전 가드레일을 최소 비용으로 구축하도록 지원하는 것을 목적으로 함
개발 환경	• HW: Windows 11 개발 환경 (별도 GPU 서버 불필요 — 경량 로컬 추론 설계)
• 언어: Python 3.13 (백엔드·SDK), TypeScript/React (프론트), JavaScript (크롬 확장)
• 프레임워크·라이브러리: FastAPI, OpenCV, NumPy, Pillow, Click, Rich, React 18, Vite 5
• 도구: Git/GitHub, uvicorn, pytest(단위 테스트 66 개), Vercel(배포)
• 배포: Vercel 서버리스(텍스트 고증) + 로컬 CLI(멀티미디어 전체 기능)
시스템 구성 및 아키텍처	• SDK 코어('truthhistory/'): 공통 규격 AnalysisResult(신뢰도·AI 확률·위험도·판정 근거)를 정의하고 텍스트/이미지/영상/오디오 4 대 분석기가 상속 구현 — 지연 로딩(Lazy Loading) 모듈러 구조로 필요 모듈만 선택 설치('pip install -e .[text

2. 프로젝트 상세 내용

핵심 기능 및 특징(특장점)

1. **4 대 탐지 모듈 단일 SDK 통합** — 텍스트 고증, ELA 이미지 합성, 딥페이크 페이스 스왑, AI 복제 음성 탐지를 하나의 규격(**AnalysisResult**)으로 통합. 하나의 역사 콘텐츠를 매체 유형과 무관하게 동일한 API·CLI·리포트 형식으로 교차 검증
2. **내장 한국사 사료 지식베이스(오프라인 고증)** — 국사편찬위원회 「한국사연표」 기반 연표·인물 데이터를 SDK 에 내장, 네트워크·API 키 없이 "사건/인물 × 연도(세기)" 주장을 즉시 교차 검증. 예: **"임진왜란은 1920 년에 발발"**(1592–1598 과 상충), **"세종대왕이 1592 년에 전쟁 지휘"**(활동기 1397–1450 밖) → 강한 할루시네이션 신호로 판정
3. **설명 가능한 판정(XAI)** — 단순 Pass/Fail 이 아닌 판정 근거(연표 상충 상세, ELA 편차, FFT 스파이크, 프레임 Jitter 지수, 증거 출처 URL)를 구조화 JSON 으로 반환

4. **실시간 대응 계층** — ① 크롬 확장: ChatGPT/Claude/Gemini 답변에 실시간 신뢰도 배지 + 우클릭 범용 검사 ② `th stream`: 라이브 RTSP/웹캡처 영상을 2 초 청크로 증분 분석(CRITICAL 조기 종료) ③ MCP 서버: Claude 등 LLM 에이전트 직접 연동
5. **경량·저비용 구조** — 무거운 모델 없이 규칙·신호 분석 + 선택적 GPT-2 구동으로 자체 검증 레이어 구축 비용 절감. Vercel 무료 티어로도 텍스트 고증 서비스 즉시 배포 가능(라이브: <https://platy-rho.vercel.app>)

개발 과정(주요 단계 및 방법)

단계	내용
1. 코어 설계	공통 DTO(<code>AnalysisResult</code>)- <code>BaseAnalyzer</code> 추상화로 4 개 분석기 규격 통일, 지연 로딩 임포터로 선택 설치 구조 구현
2. 분석 엔진	모듈별 탐지 알고리즘 구현(ELA/FFT, 히스토그램 기반 Jitter, 안면 비대칭, MFCC/HNR) 및 휴리스틱 스코어링 가중치 설계
3. 고증 계층 고도화	한국사 연표 KB 내장 → 연도 주장 교차 검증 결합, 외부 검색 증거 병렬 수집(스레드 풀), 시대착오 탐지
4. 통합 환경	FastAPI 게이트웨이, 통합 CLI(<code>th</code>), React 대시보드, Vercel 서버리스 배포, 크롬 확장(Manifest V3), stdio MCP 서버 구현
5. 실시간 계층	스트리밍 청크 분석기(제너레이터 증분 처리·조기 종료·최악 청크 보수 종합) 및 OpenRouter 무료 LLM 심사 경로 추가(키 없이도 전 기능 동작하는 독립 구동 유지)
6. 품질 관리	단위 테스트 66 개(목킹 기반 증거 소스·스트리밍 청크·KB·LLM 폴백), 전 CLI 명령·REST 엔드포인트 8 종·프론트 빌드 실측 디버그 패스 수행

3. 구동 및 시연

항목	내용
설치	<code>git clone https://github.com/kimneche0419-rgb/Thruth_History</code> → <code>pip install -e .[all]</code> → <code>th init</code>

텍스트 고증	<code>th scan "임진왜란은 1592 년에 발발했다" → 신뢰도·위험도·판정 근거 출력(-f json XAI 리포트). URL 은 th scan "https://ko.wikipedia.org/wiki/임진왜란"</code>
멀티미디어	<code>th scan photo.jpg / th scan video.mp4 / th scan voice.wav — 확장자 자동 분기</code>
스트리밍	<code>th stream rtsp://... / th stream 0(웹캠) — 청크별 실시간 신뢰도 타임라인 출력</code>
대시보드·API	<code>th dev(API 8000 + 대시보드 5173 동시 기동), POST /api/v1/scan/{text,url,media,stream}</code>
크롬 확장	<code>chrome://extensions → 개발자 모드 → extension/ 폴더 로드 → ChatGPT 등에서 역사 답변에 배지 자동 표시(백엔드 설정 불필요, Vercel 자동 연동)</code>
MCP	<code>th mcp — Claude Desktop 등에서 scan_text/scan_file 도구로 연동</code>
종료 코드	CLI <code>0=정상 / 1=변조 의심 / 2=오류</code> — CI/CD 자동 차단 게이트로 바로 적용 가능
테스트	<code>python -m pytest tests/ — 단위 테스트 66 개 전체 통과</code>

4. 기대효과 및 활용 분야

기대효과

- 오염된 거짓 역사 정보와 위변조 콘텐츠를 **생성·유포 단계에서 조기 차단** → 정보 환경 투명성 확보 및 디지털 역사 주권 수호
- 파편화된 탐지 기능의 통합 규격화 + 경량 추론 설계로 **자체 검증 레이어 구축 비용 대폭 절감**
- 판정 근거를 XAI 로 공개해 블랙박스 판정이 아닌 **감사 가능한 검증** 제공

활용 분야 및 시장성

- **뉴스·언론**: 역사 관련 제보·기사의 사료 교차 검증, 합성 사진·사칭 발언 사전 차단
- **교육·출판**: 교재·학습 자료·과제의 한국사 고증 오류 및 AI 생성 검증 (규칙 기반 연표 검증은 수업 환경에서 네트워크 없이도 동작)

- **SNS·플랫폼**: 역사 왜곡 콘텐츠 확산 실시간 모니터링(CI 종료 코드·REST API·스트리밍 게이트웨이로 직접 연동)
- **AI 에이전트 생태계**: MCP 서버·크롬 확장으로 LLM 활용 계층 전반에 가드레일 공급

5. 기타

프로젝트의 혁신성 및 차별성

- 국내외 공개 프로젝트 중 **한국사 특화 고증(연표 KB + 시대착오 + 외부 사료 증거)과 멀티미디어 위변조 탐지를 단일 SDK로 통합한 사례가 없음** — 기존 딥페이크 탐지기·팩트체크 API는 단일 기능에 파편화
- **오프라인 결정론 고증 계층** 내장: 네트워크·API 키 의존 없이 즉시 판정 → 어떤 인프라에도 무조건 임베딩 가능 (외부 API는 부가 경로일 뿐)
- 크롬 확장 → CLI → REST → MCP 까지 **동일 검증 엔진을 5개 채널로** 노출: LLM 소비자(개인)부터 플랫폼(기업)까지 수평 적용

한계점 및 향후 발전 로드맵

- 한계: ① 내장 KB가 주요 사건 41건·인물 15명 규모(커버리지 확대 필요) ② 정량 벤치마크 데이터셋·성능 지표 미보유 ③ ELA/주파수 분석의 오탐 저감 여지
- 로드맵(단계별 상세: 저장소 [ROADMAP.md](#)): Phase 1 벤치마크 데이터셋·정확도 리포트·시연 영상 → Phase 2 국사편찬위원회 공개 데이터(공공데이터포털) 직접 연동, KB 200건+ 확대, VSCode 확장, 오디오 스트리밍 → Phase 3 CI/CD·PyPI 배포·크롬 웹스토어 게시·영문 문서화·기여 가이드라인

소감 및 후기

- "한국사 할루시네이션"이라는 국내 특화 문제를 글로벌 오픈소스 생태계(MCP·크롬 확장·SBOM 준수)와 접목한 설계 경험 확보
- 오프라인 우선(offline-first) 증거 계층을 먼저 만들고 외부 API를 부가 경로로 붙이는 설계로, 외부 의존 없이도 판정이 유지되는 회복성 있는 아키텍처를 구현한 점이 기술적 성취
- 테스트 66개·전 엔드포인트 실측의 디버그 패스를 통해 "데모형 프로토타입"이 아닌 검증 가능한 품질의 프레임워크로 발전시킴

붙임 1. SBOM(소프트웨어 자재명세서)

선별 기준(①GPL/AGPL/LGPL 계열 → ②핵심 기능 → ③주요 프레임워크·SDK → ④핵심 빌드·실행 도구)

적용. 본 프로젝트는 GPL 계열 의존성 없음.

번호	라이브러리명	버전	라이선스	공식 저장소 URL	사용 목적 및 주요 기능
1	OpenCV (opencv-python)	4.12.0	Apache-2.0	github.com/opencv/opencv	이미지·영상 프레임 처리(ELA/답페이지 분석) / 라이브러리로 불러 씸
2	NumPy	2.2.6	BSD-3-Clause	github.com/numpy/numpy	ELA·FFT·Jitter 수치 연산 / 라이브러리로 불러 씸
3	Pillow	12.0.0	MIT-CMU	github.com/python-pillow/Pillow	이미지 로드·재인코딩(ELA) / 라이브러리로 불러 씸
4	FastAPI	0.129.0	MIT	github.com/tiangolo/fastapi	백엔드 REST API 서버 / 라이브러리로 불러 씸
5	Pydantic	2.12.3	MIT	github.com/pydantic/pydantic	분석 결과 DTO 스키마·검증 / 라이브러리로 불러 씸
6	Click	8.3.1	BSD-3-Clause	github.com/pallets/click	통합 CLI(th) 프레임워크 / 라이브러리로 불러 씸
7	Rich	14.2.0	MIT	github.com/Textualize/rich	CLI 테이블·진행률 출력 / 라이브러리로 불러 씸
8	requests	2.32.5	Apache-2.0	github.com/psf/requests	외부 검색 증거 수집 HTTP

					클라이언트 / 라이브러리로 불러 씀
9	React	18.2.0	MIT	github.com/facebook/react	대시보드 프론트엔드 / 라이브러리로 불러 씀
10	Vite	5.4.21	MIT	github.com/vitejs/vite	프론트엔드 빌드·개발 서버 / 빌드 도구로 사용

※ 전체 의존성 목록은 저장소의 `requirements.txt`·`package.json` 참조.

붙임 2. AI 모델 활용 및 라이선스 기술 명세서

1. AI 모델 활용 유형 (해당하는 항목에 ☒ 표시)

- ☒ 유형 1: 외부 모델 그대로 활용 (추가 학습 없이 기존 공개 모델을 프로젝트에 연동·구동한 경우)
- ☐ 유형 2: 외부 모델 파인튜닝
- ☐ 유형 3: 자체 개발 모델

2. 기반(베이스) 모델 정보

항목	내용
기반 모델명 및 개발사	GPT-2 (OpenAI) — transformers 로 직접 다운로드·로컬 구동, Perplexity 산출에 활용(추가 학습 없음). 미설치 환경에서는 어휘 다양도 휴리스틱으로 자동 폴백
기반 모델 라이선스	MIT License (github.com/openai/gpt-2) — 승인 절차 없이 누구나 내려받아 사용 가능한 오픈웨이트 모델

외부 API 경로 및 독립 구동성(참고)

- (선택) OpenRouter :[free](#) 오픈웨이트 모델(기본 [meta-llama/llama-3.3-70b-instruct:free](#))로 한국사 텍스트 LLM 심사 경로를 제공하나, `OPENROUTER_API_KEY`

없이도 전체 핵심 기능(연표 KB·외부 검색 증거·GPT-2 로컬 추론)이 동작하는 독립 구동
경로를 기본으로 두었음(외부 상용 API 의존 단순 연결이 아님). OpenRouter 는 키를
.env 에 입력한 경우에만 활성화되는 부가 심사 경로임

3. 데이터셋 정보 및 가중치 배포 명세 (유형 2.3 작성 필수)

- 해당 없음 (유형 1 로, 추가 학습을 수행하지 않아 새로 생성된 가중치가 없음)
- 내장 한국사 연표 KB(사건 41 건·인물 15 명)는 국사편찬위원회 「한국사연표」 공개
사실관계를 출처 표기 하에 큐레이션한 코드 내 데이터(모델 학습 아님)

4. 소스코드 라이선스 및 개발 환경 정보 (모든 유형 필수 작성)

항목	내용
직접 작성한 코드의 오픈소스 라이선스	MIT License (OSI 인증)
학습/추론 소스코드 공개 저장소 URL	https://github.com/kimneche0419-rgb/Thruth_History (공개 유지)
상용 AI 보조도구 활용 여부 및 범위	코드 작성·디버깅·테스트 보조 목적으로 Claude 기반 AI 어시스턴트를 활용(전체 코드의 상당 부분 초안 생성에 보조 활용). 핵심 분석 알고리즘 설계·데이터 규격 정의·아키텍처 결정·코드 리뷰·동작 검증(66 개 테스트·전 엔드포인트 실측)은 팀이 직접 수행했으며, 전체 코드의 동작 원리를 이해·설명 가능함